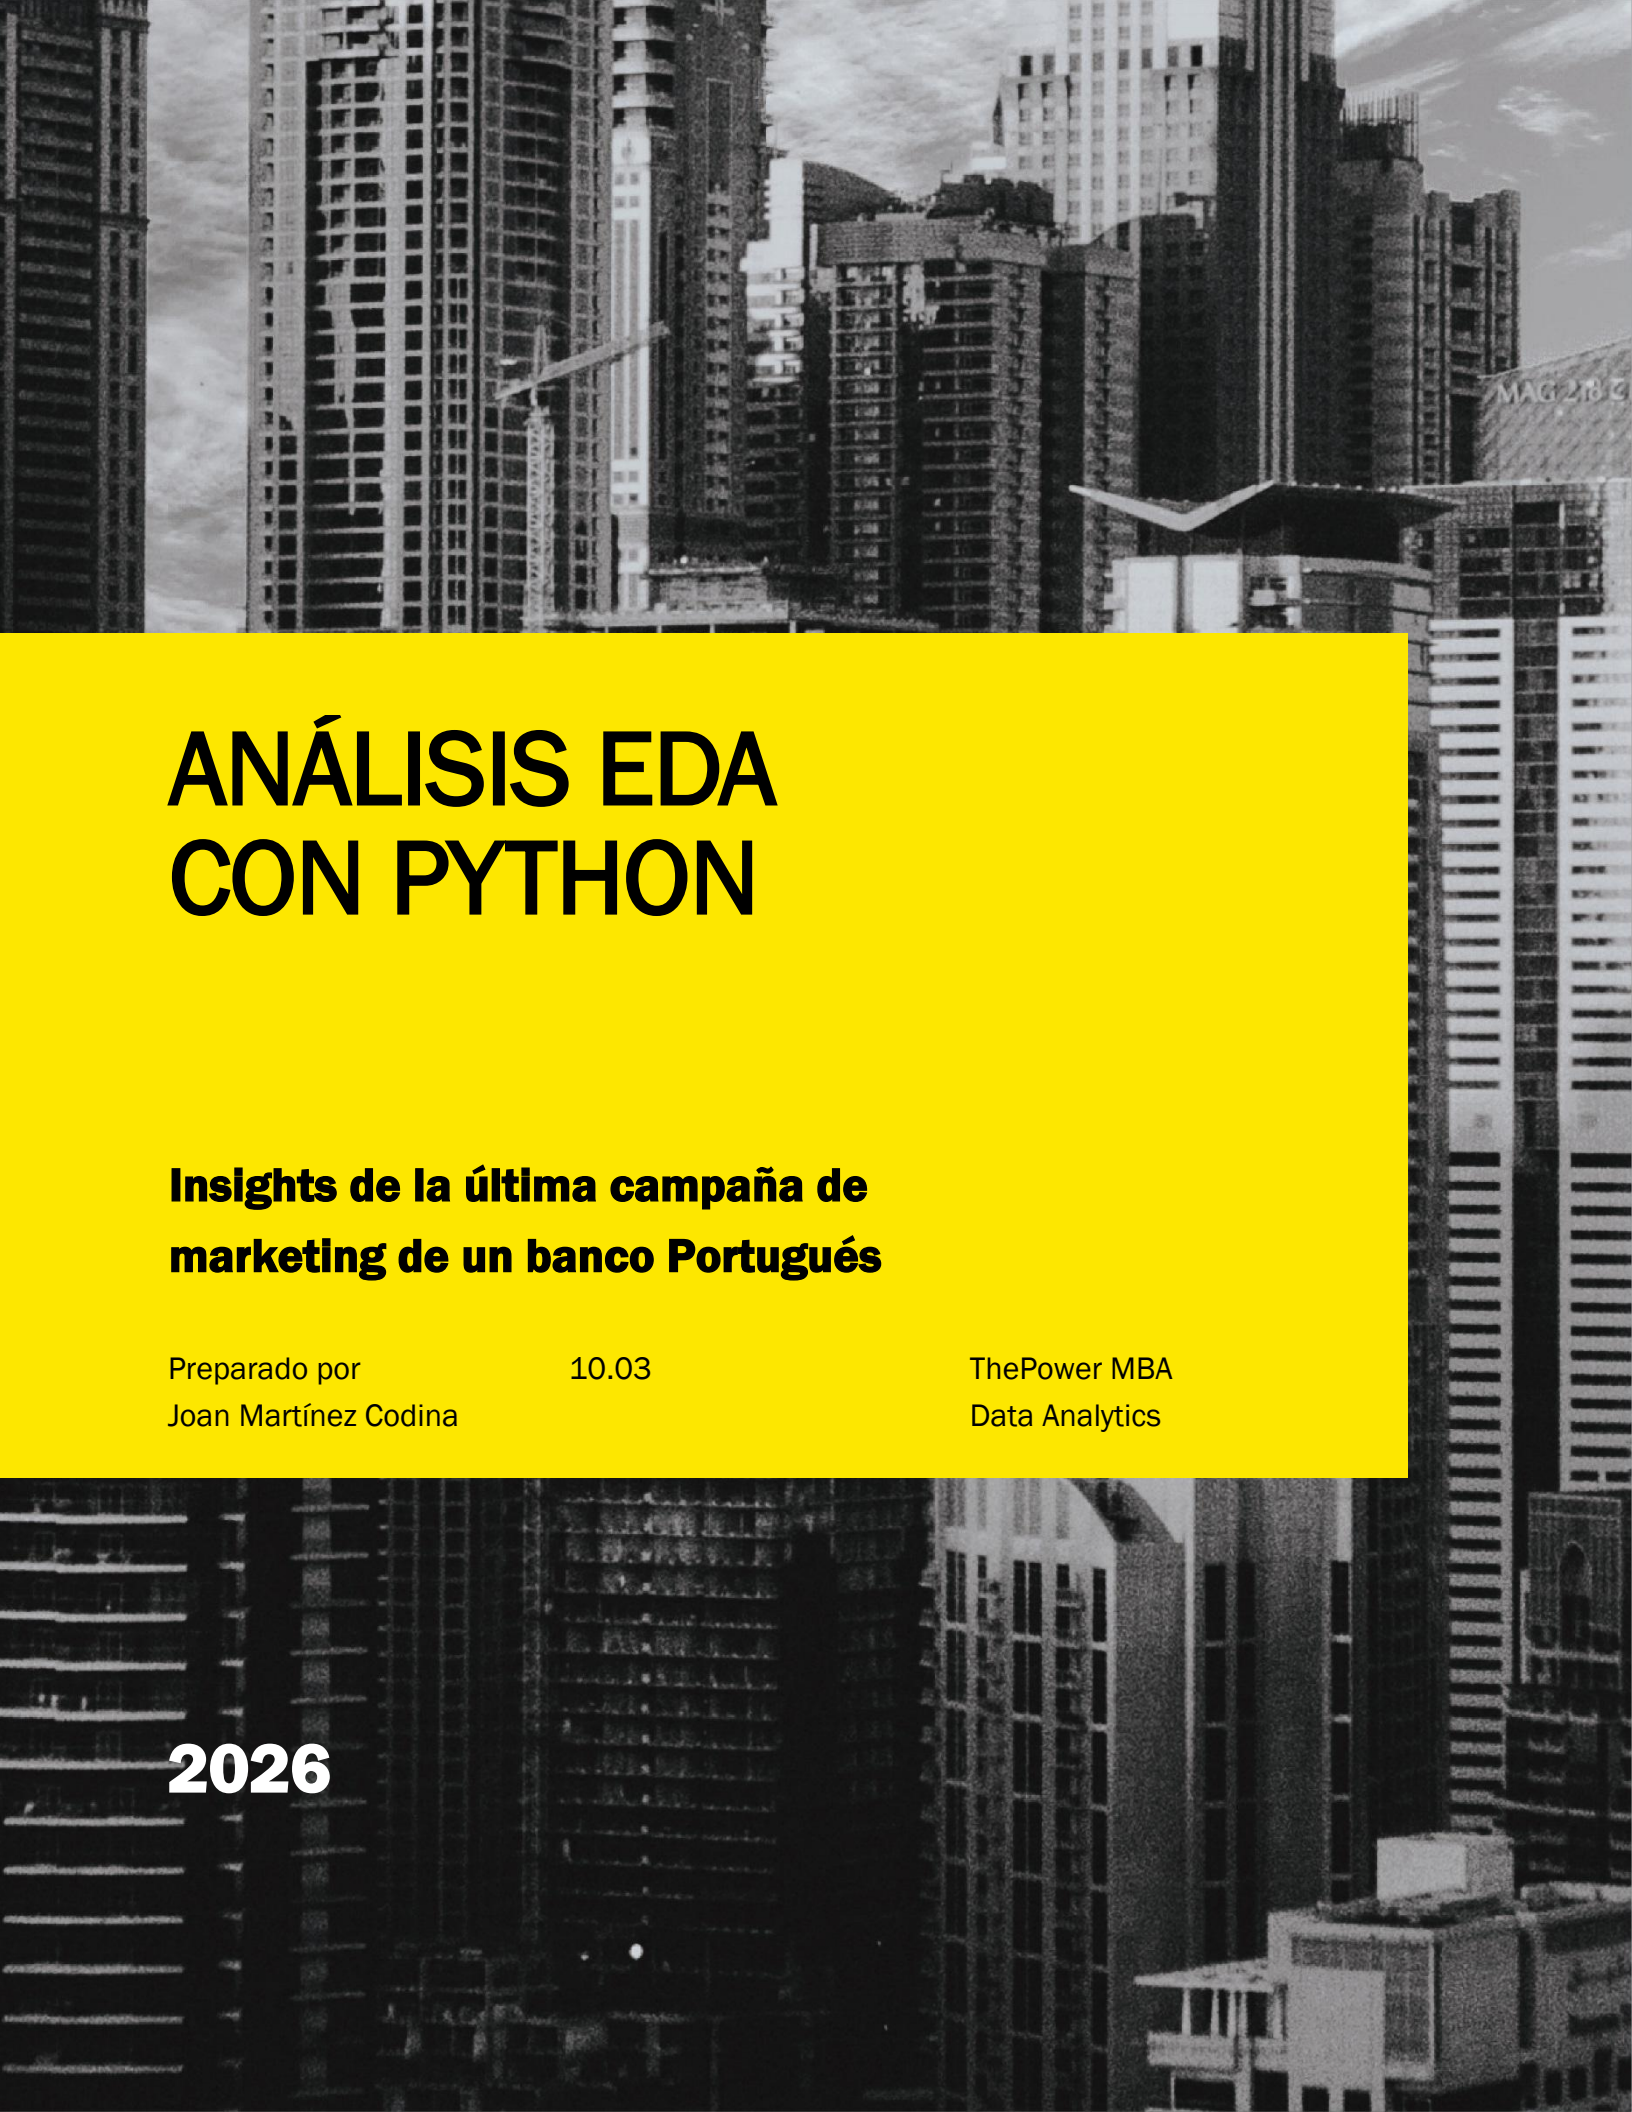

ANÁLISIS EDA CON PYTHON

Insights de la última campaña de marketing de un banco Portugués

Preparado por
Joan Martínez Codina

10.03

ThePower MBA
Data Analytics

2026

Tabla de Contenidos

Portada 1
Introducción 3
Carga y Preparación de los Datos 3
Integración de las Fuentes de Información 3
Tratamiento de Valores Nulos 3
Estadísticas Descriptivas 4
Análisis Univariado 4
Análisis Bivariado 6
Variables Categóricas frente a la Variable Objetivo 6
Variables Numéricas frente a la Variable Objetivo 7
..... 7
Análisis de Correlaciones 8
Conclusiones y Recomendaciones 9
Conclusiones 9
Recomendaciones 9
Próximos Pasos 9

Introducción

El presente documento tiene como objetivo desarrollar un análisis exploratorio de datos (EDA) sobre las campañas de marketing telefónico llevadas a cabo por una institución bancaria portuguesa. Estas campañas, cuyo propósito principal es la promoción de depósitos a plazo fijo, dependen de la segmentación adecuada de los clientes para lograr una mayor eficacia.

El análisis exploratorio permite comprender la estructura de los datos, identificar patrones de comportamiento y detectar posibles relaciones entre las características de los clientes y la probabilidad de aceptación de las ofertas propuestas.

Para llevar a cabo el estudio, se han utilizado dos fuentes de datos principales: el archivo bank-additional.csv, que contiene información relativa a las campañas y variables macroeconómicas, y el archivo customer-details.xlsx, que aporta información demográfica y de comportamiento de los clientes en distintos periodos. La integración de ambas fuentes facilita una visión más completa del perfil de cliente y de los factores que influyen en la conversión de las campañas.

Carga y Preparación de los Datos

Integración de las Fuentes de Información

Como primer paso, se realizó la lectura de los archivos bank-additional.csv y customer-details.xlsx, este último compuesto por varias hojas correspondientes a diferentes años. Fue necesario consolidar todas las hojas en un único conjunto de datos. Posteriormente, se efectuó una unión (left join) utilizando los identificadores únicos de cada tabla, lo que permitió preservar toda la información de las campañas y añadir las características adicionales de los clientes. Así se obtuvo un dataset unificado para el análisis posterior.

Tratamiento de Valores Nulos

Tras la integración, se revisaron exhaustivamente los valores faltantes o inconsistentes. Para las variables numéricas, como age, duration, euribor3m e income, se sustituyeron los valores nulos por la media de la variable, manteniendo la distribución general. En el caso de variables categóricas (job, education, marital), se imputó la moda. Para variables binarias (default, housing, loan), se asignó el valor -1 para indicar información desconocida. Finalmente, se verificó la existencia de duplicados y se realizó un análisis preliminar de valores atípicos, considerando que los extremos detectados eran coherentes con el contexto del dataset.

Estadísticas Descriptivas

El proceso de limpieza permitió calcular estadísticas descriptivas básicas para entender mejor las características generales del dataset. Entre las métricas analizadas se incluyen la media, mediana, desviación estándar, valores mínimo y máximo, y percentiles. Estas estadísticas ofrecen una primera aproximación al comportamiento de las variables y ayudan a detectar asimetrías o dispersiones relevantes. Variables como la edad, los ingresos o la duración de la llamada muestran diferentes niveles de variabilidad, reflejando la heterogeneidad de los perfiles de cliente.

Estadísticas descriptivas básicas:

	mean	median	std	min
age	39.977112	39.977112	9.796944	17.000
Income	93239.606340	93050.000000	50497.821959	5841.000
duration	257.739203	179.000000	258.669041	0.000
NumWebVisitsMonth	16.589409	17.000000	9.239119	1.000
euribor3m	3.616484	4.076000	1.538840	0.634
nr.employed	5166.852041	5191.000000	72.411874	4963.600
cons.price.idx	93.574209	93.574209	0.576369	92.201

	max
age	98.000
Income	180802.000
duration	4918.000
NumWebVisitsMonth	32.000
euribor3m	5.045
nr.employed	5228.100
cons.price.idx	94.767

Análisis Univariado

El análisis univariado se centra en la distribución individual de cada variable, utilizando histogramas para variables numéricas y gráficos de barras para las categóricas. Se detectó un fuerte desbalance en la variable objetivo (y): aproximadamente el 88% de los clientes no suscriben el depósito, mientras que el 12% sí lo hacen. Esta situación, común en campañas de marketing, representa un reto para el modelado predictivo. El ingreso (income) tiene una distribución asimétrica hacia la derecha, con mayor concentración en rangos salariales de 30.000 a 60.000 euros. La duración de las llamadas suele ser inferior a 300 segundos, aunque existe un grupo de llamadas mucho más largas. Las categorías más frecuentes en variables demográficas son job (admin., technician), education (university.degree) y marital (married), reflejando la diversidad del perfil de cliente.

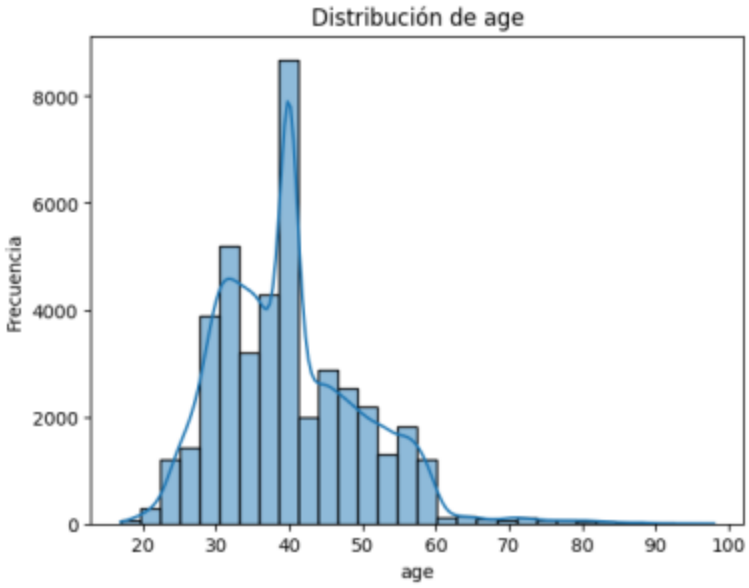
Distribución de age
Frecuencia
8000
6000
4000
2000
0
20
30
40
50
60
70
80
90
100
age

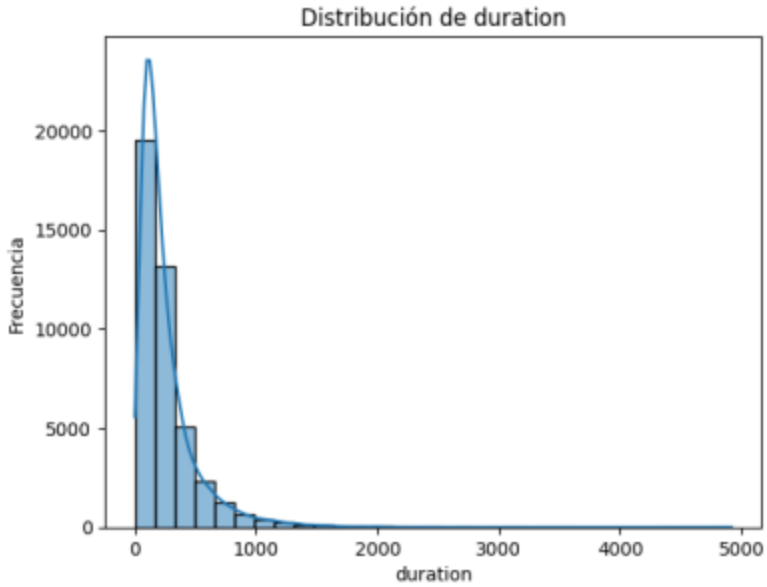
Distribución de duration
Frecuencia
20000
15000
10000
5000
0
0
1000
2000
3000
4000
5000
duration

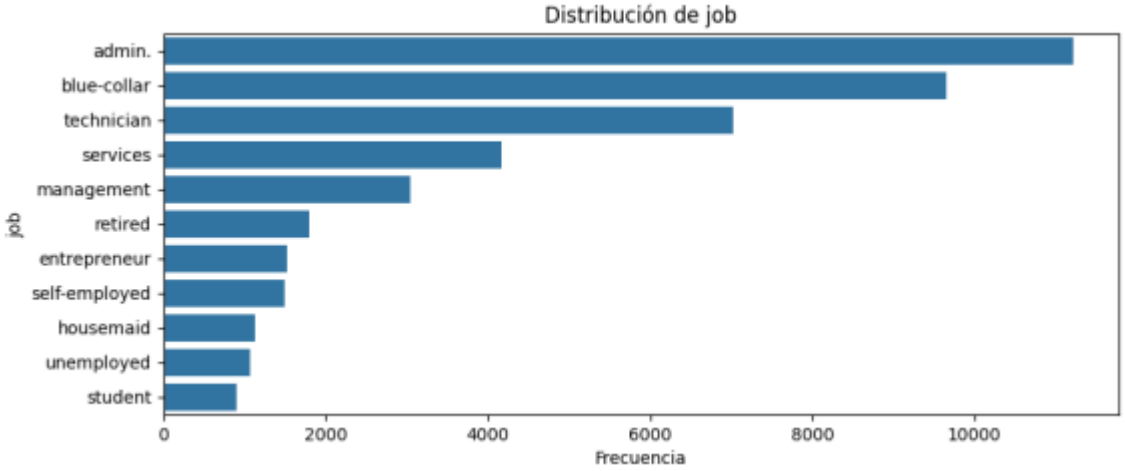
Distribución de job
job
admin.
blue-collar
technician
services
management
retired
entrepreneur
self-employed
housemaid
unemployed
student
0
2000
4000
6000
8000
10000
Frecuencia

Análisis Bivariado

Variables Categóricas frente a la Variable Objetivo

Se calcularon tasas de conversión para cada categoría de las variables categóricas. Los clientes clasificados como retired y student presentan tasas de conversión superiores a la media. Aquellos con estudios superiores, especialmente university.degree, muestran mayor probabilidad de aceptar la oferta. Los clientes solteros tienden a convertir ligeramente más que casados o divorciados. Además, quienes no tienen préstamos activos muestran una mayor predisposición a contratar el depósito, sugiriendo que ciertos perfiles son más receptivos a estos productos financieros.

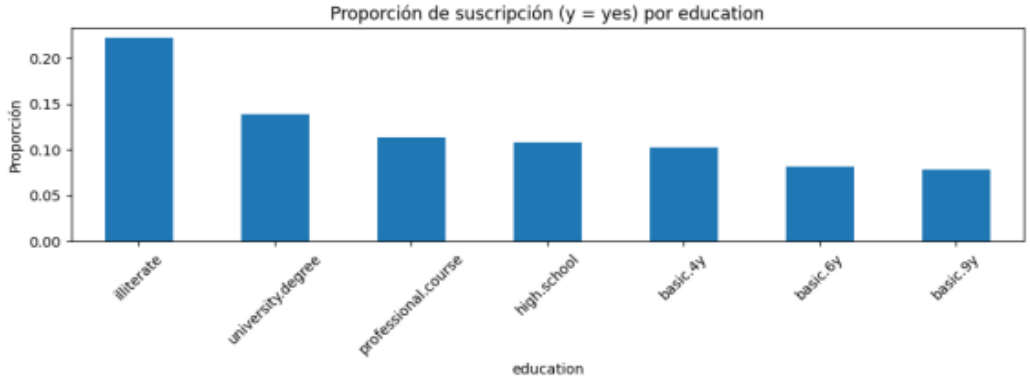

Variables Numéricas frente a la Variable Objetivo

La duración de la llamada es el factor más determinante en la conversión: las llamadas que terminan en suscripción suelen ser considerablemente más largas, especialmente aquellas superiores a 400 segundos. No se observan diferencias claras en la edad o los ingresos entre grupos de clientes que convierten y los que no. En NumWebVisitsMonth, hay una ligera tendencia a valores más altos en quienes no convierten, lo que puede indicar que estos usuarios exploran información, pero no toman la decisión final de contratar.

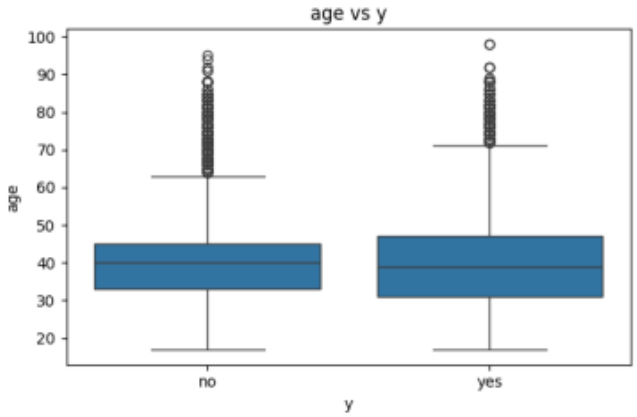

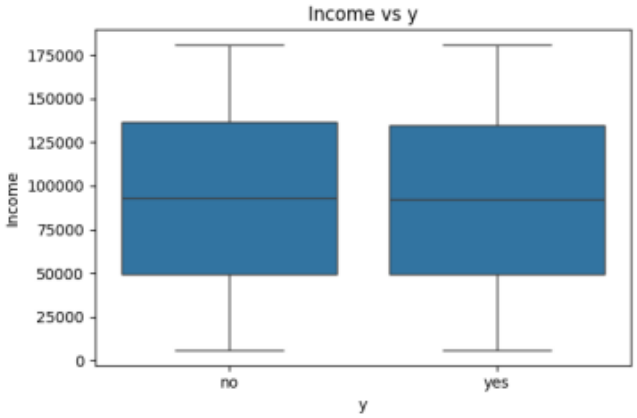

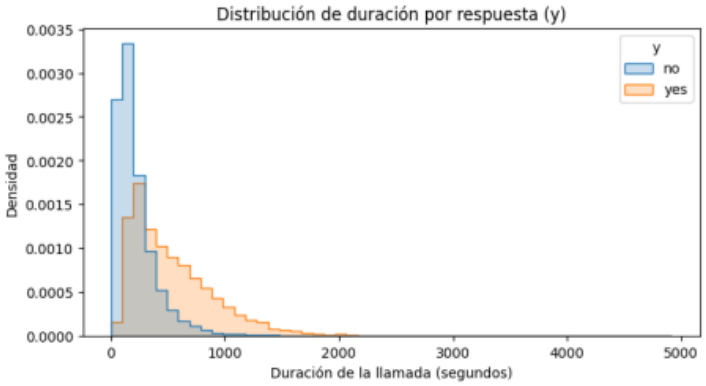

Análisis de Correlaciones

Se elaboró una matriz de correlación entre variables numéricas para identificar relaciones lineales. Se detectó alta correlación entre variables macroeconómicas (euribor3m, nr.employed, cons.price.idx). La variable duration presenta baja correlación con la mayoría, pero sí guarda relación significativa con la variable objetivo. Income y age muestran correlaciones bajas con el resto de variables. Estos resultados sugieren que las variables económicas reflejan el contexto macroeconómico, mientras que la duración de la llamada capta aspectos del proceso de interacción con el cliente.

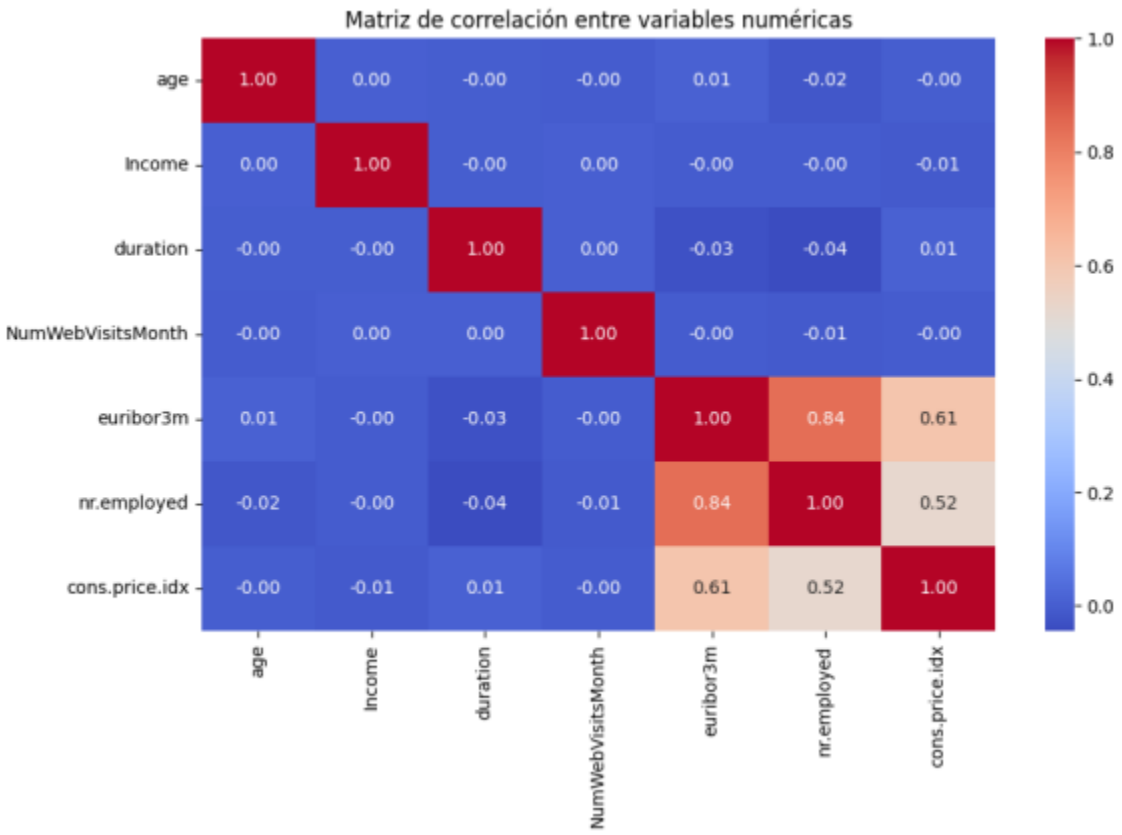

Conclusiones y Recomendaciones

Conclusiones

El análisis exploratorio confirma que la duración de la llamada es el factor más determinante para la conversión de clientes. Perfiles como estudiantes y jubilados tienen mayor predisposición a contratar depósitos a plazo. Variables demográficas como edad e ingresos no muestran diferencias marcadas entre quienes aceptan o rechazan la oferta. Finalmente, las variables macroeconómicas están interrelacionadas, pero no explican directamente el comportamiento individual de los clientes.

Recomendaciones

Se recomienda optimizar la duración de las llamadas, segmentar campañas priorizando perfiles con mayores tasas históricas de conversión, implementar modelos predictivos para identificar clientes con mayor probabilidad de contratación y mejorar el seguimiento de interesados, especialmente aquellos que ya han mostrado interacción previa con el banco.

Próximos Pasos

Como continuación del análisis exploratorio, se plantea desarrollar modelos de machine learning para predicción de conversión, evaluar algoritmos como regresión logística, random forest y gradient boosting, implementar técnicas para tratar el desbalance de clases y crear dashboards interactivos para monitorizar el rendimiento de futuras campañas. Estos pasos permitirán convertir los resultados del análisis en herramientas operativas de apoyo a la toma de decisiones.